Rapport de Stage : Projet Flinovo
Analyses en single cell des réponses de patients atteint de lymphome folliculaire à un traitement, le RCHOP.

LIPINSKI Boris

Contrat d'alternance
Septembre 2020 à Aout 2021

Maitre d'apprentissage : SUJOBERT Pierre
Tuteur pédagogique : BROCHIER Céline
Entreprise d'acceuil : Laboratoire UR LIB « Lymphoma Immuno-Biology », Équipe Gilles Salle.
Etablissement : Université de Claude Bernard Lyon 1, Faculté de Médecine Lyon-Sud.
Formation : Master 2 Bioinformatique Moléculaire, Méthodes et Analyses.

Résumé

Table des Matières

1. Liste des abréviations utilisées 1
2. Liste des logiciels utilisés 1
3. Section principale 2
   - 3.1 Introduction 2
   - 3.2 Matériels et méthodes 5
   - 3.3 Résultats 10
   - 3.4 Discussion 10
   - 3.5 Conclusion 12

4.Bibliographie 12

Table des Figures

1 Workflow des analyses du projet FLINOVO 11

1. Liste des abréviations utilisées

- item 1

2. Liste des logiciels utilisés

- R: 4.0.5 (2021-03-31) Shake and Throw
  - Seurat : 4.0.0
  - SingleR : 1.4.1
  - celldex : 1.0.0
  - scRNAseq : 2.4.0
  - CellSIUS : 1.0.0
  - ggplot2 : 3.3.3

  - plotly : 4.9.3
  - shiny : 1.6.0
  - shinyjs : 2.0.0
  - shinydashboard : 0.7.1
  - Signac : 1.1.1
  - scone : 1.14.0
  - escape : 1.1.1
  - dittoSeq : 1.2.5
  - shinyWidgets : 0.5.7
  - monocle : 2.18.0
  - cowplot : 1.1.1
  - scran : 1.18.5
  - clues : 0.6.2.2
  - TENxBUSData : 1.4.0
  - dplyr : 1.0.5
  - tidyverse : 1.3.0
- Python : 3.8.3
  - pandas : 1.1.4
  - plotly : 4.14.3
  - seaborn : 0.11.1
  - numpy : 1.19.4
  - scipy : 1.5.4
  - matplotlib : 3.3.2
  - jupyter-notebook : 6.2.0
- CellRanger : count, VDJ
- CITE-SEQ count :
- IronThrone-GoT : 2.1

3. Section principale

3.1 Introduction

Une introduction présentant l'état de l'art et le contexte scientifique dans lequel s'inscrit le travail réalisé ainsi que la(les) problématique(s) abordées pendant le stage ;

De nombreux processus sont impliqués dans le développement et l'évolution du cancer. L'expansion de cellules tumorales dans l'organisme va de pair avec l'accumulation d'altérations génétiques induites par mutations somatiques. blablabla...

Contexte scientifique

Le cancer se caractérise par l'apparition de cellules qui échappent aux systèmes de contrôle du cycle cellulaire. Ces cellules dites tumorales acquiescent la capacité de proliférer de façon incontrôlée, leur progression et leur adaptation à l'environnement suivent principalement des processus évolutifs. Il est généralement accepté que les cellules tumorales sont issues d'une seule cellule donnant lieu à des sous-populations caractérisées par l'accumulation de nombreuses nouvelles altérations génétiques. En effet, génération après génération la diversité génétique au sein de la population cellulaire tend à s'accroître par acquisitions successives de mutations somatiques[1] pouvant favoriser l'apparition de cellules de plus en plus dysfonctionnelles. Ainsi certaines cellules s'écartent des processus physiologiques standards jusqu'à échapper à l'immuno-surveillance, les rendant donc potentiellement précurseures de tumeurs cancéreuses malignes. De ce fait, le cancer découle de dynamiques cellulaires et moléculaires complexes et anormales, suivant des modèles d'expansion clonale et de diversité très variable à la fois selon le type de cancer et selon l'individu.

Parmi les différents types de cancers se trouve le diagnostique du lymphome folliculaire, une tumeur maligne incurable des lymphocytes B qui compte pour 25% des lymphomes, soit le 2ème lymphome par ordre de fréquence. La manifestation des symptômes cliniques est en grande partie indolore, s'exprimant principalement via gonflements des ganglions lymphatiques dans les régions du cou, des aisselles ou de l'aine. En dépit des progrès récents de notre compréhension sur la physiopathologie de ce cancer[2] cette maladie est toujours considérée comme étant incurable, et la plupart des patients atteints en décèdent des années après le diagnostic.

Administrer un traitement revient toujours à être délicat quel que soit le cancer diagnostiqué. Au-delà des effets curatifs thérapeutiques primaire et secondaire connus et attendus, le résultat peut tout aussi se révéler être inattendu, amplifiant une certaine progression tumorale pour des lignées cellulaires résistantes, favorisées par pressions de sélections et donc éliminant progressivement toutes autres cellules sensibles au traitement[3]. Ainsi une adaptation et une résistance au traitement des sous-populations cellulaires déjà existantes peuvent apparaitre par sélection darwinienne, phénomène souvent grandement impliqué dans l'échec thérapeutique.

Dans le contexte du lymphome folliculaire, il a été montré que la majorité des patients parviennent à une rémission complète s'ils sont soumis au traitement composé à base de RCHOP, ensemble de 5 molécules thérapeutiques : Rituximab, Cyclophosphamide, Hydroxyadrimycine, Vincristine et Prendisone[4]. Cependant, un grand nombre de patients ont été victimes de rechute post-traitrement pouvant mener jusqu'à la mort, principalement à cause de toxicités liées au traitement même ou bien à une progression incontrôlable et inattendue de la maladie[5].

Caractériser et prédire au mieux la réponse clinique aux traitements constitue donc un des enjeux majeurs liés à cette problématique biologique. Cela pourrait se montrer être décisif dans la compréhension de l'évolution tumorale face au traitement, afin de maximiser à terme les chances de guérison des patients.

De nos jours, il est d'ores et déjà possible d'entrevoir que des analyses nécessitant un tel degré de précision soient réalisables. En effet, l'efficacité technologique des méthodes d'analyse en single-cell est telle qu'elles permettent de caractériser les populations cellulaires intra-tumorales au plus haut degré de précision possible, tant au niveau ADN qu'ARN.

Les outils de RT-qPCR ont d'abord montré que le single-cell peut être utilisé pour étudier les changements d'expressions par gène et par cellules au cours de la différenciation embryonnaire[6]. L'évolution complexe de populations cellulaires a aussi pu être caractérisée par méthode de séquençage et d'analyse cellulaire RNA-seq en single-cell, permettant l'observation de trajectoires de différenciation de lignées distinctes, de l'hétérogénéité transcriptionnelle associée au cycle cellulaire et des programmes cellulaires de résistance aux médicaments impliqués[7][8]. La profondeur analytique que permettent les techniques en single cell semblent donc tout à fait pertinantes pour apporter des éléments analytiques à la fois vastes, précis et cohérent avec notre problématique.

L'utilisation du single cell impose l'optimisation du séquençage lui-même par l'utilisation d'identificateurs moléculaires uniques (UMI). L'incorporation d'un barcode dans l'étape de reversetranscription du séquençage permet d'assigner chaque read séquencé issu de transcrits exprimés à la cellule d'origine. La précision du comptage de transcrits et la reproductibilité de quantification en single-cell s'en retrouve donc bien meilleure, tout en supprimant efficacement les biais de réplicats induits par la PCR, vecteur de surexpression génique factice[7]. C'est ainsi que des comportements et sous-types de populations cellulaires peuvent être identifiés sur la base d'observation des résultats d'analyses transcriptomiques.[8][9]

C'est en prenant parti des avancées technologiques que des industries telles que 10X Genomics ont pu de s'agrandir, mettant toujours à disposition des techniques de séquençage de pointe utilisable pour la recherche scientifique, notamment en single cell. Les outils analytiques proposés par 10X Genomics permettent l'investigation d'analyse intégrative en single cell de populations tumorales à des niveaux phénotypiques, transcriptomiques et génétiques, et leur application se trouve donc être en adéquation parfaite notre projet.

C'est dans ce contexte biologique que se projette le travail effectué pendant ce contrat d'alternance, illustrant le lancement d'un projet appelé FLINOVO. Comprendre et quantifier l'ampleur des effets du RCHOP sur des patients constitue notre problématique et nécessite de comparer l'état des mêmes cellules avant et après traitement. Ainsi cette étude souhaite inclure à terme l'analyse 30 patients atteints du cancer du lymphome folliculaire soumis au RCHOP, parmi lesquels 2 réponses cliniques ont principalement été observées : 14 patients ont eu une réponse favorable au traitement sans rechute par la suite, 16 ont eu une réponse partielle et/ou une rechute rapide de la maladie. L'application d'un nouveau modèle expérimental basé sur la xénogreffe in ovo de cellules d'intérêts sur des embryons de poulet permettant simultanément d'observer l'état des cellules soumises et non soumises au traitement. L'hypothèse testée ici est de savoir si la xénogreffe in ovo permet de prédir la réponse clinique au traitement, et constitue le coeur de la problématique de ce projet et de ce rapport.

Problématiques abordées pendant le stage

Prédir la réponse clinique au traitement de patients atteints de lymphome folliculaire et en soutirer des corrélations nécessite l'élaboration d'un protocole analytique bioinformatique à la fois vaste et profond, incluant le plus faible biais de variabilité technique possible et maximisant l'expression de la variabilité biologique d'intérêt.

D'une manière globale, cela demande de savoir manipuler différents languages de programmation, adapter des scripts exécutables sur des clusters à hautes performances, mais aussi d'avoir le recul nécessaire pour choisir pertinemment les outils et techniques d'analyse, de normalisation et de réduction de dimensions adéquates à nos données, notre méthode et notre problématique. D'autre part et plus précisément, de nombreuses recherches complémentaires sont nécessaires de manière à

donner la plus grande profondeur possible à nos analyses. Ce travail d'approfondissement divise notre objectif en plusieurs taches concrètes nécessitant à la fois d'être en mesure de reproduire des analyses issues de la littérature mais aussi de pouvoir se les approprier.

Le but est donc tout d'abord de mettre en évidence les résultats d'observations et comparaisons des tendances d'expression géniques issues des analyses en single-cell des différentes populations phénotypiques cellulaires pour chaque patient intra et inter groupes cliniques. Ces résultats se complètent grâce à des analyses d'enrichissements de gènes afin d'éclaircir la nature des fonctions cellulaires les plus impactées entre les 2 groupes de patients. En parallèle, il s'agit aussi de mettre en place le génotypage du transcriptome à l'échelle de la cellule unique de hotspot d'intérêt présent dans certains gènes à tendance anti-apoptotique ou oncogène qui joueraient un rôle déterminant dans l'apparition de lymphome folliculaire. La détection et la quantification de la présence des différentes populations de récepteurs BCR au sein des populations polyclonales des lymphocytes B issus des populations cellulaires tumorales sont aussi à réaliser en tandem, tout comme l'analyse de l'état du cycle cellulaire dans lequel ces dernières se trouvent.

La superposition de l'ensemble de ces informations et d'autres pour chacune des cellules d'intérêt constituent aussi en soi une tache à réaliser, relatant d'un aspect plus technique que biologique. Cette dernière tache introduit la besoin d'aborder la problématique de clusterisation et de réduction de dimension de notre jeu de données, afin d'identifier quelles informations expliquent le plus de variance. De plus, il est nécessaire de mettre en place des outils analytiques purement technique de manière à rendre la réalisation la visualisation des analyses simples, facilement compréhensible, automatisable et à la portée de biologiste et médecin non bio-informaticien. Dans le prolongement des taches techniques, des compétences purement informatiques sont requises. L'identification pertinante des ressources CPU, RAM et stockage a dû être nécessaires afin de rendre les calcules réalisables, car un tel projet basé sur l'utilisation des techniques en single cell amène forcément à la génération d'un grand nombre de données extrêmement volumineuses.

Enfin de par la nature purement exploratoire du projet et le fait qu'aucun résultat à priori n'est attendu, les taches décrites ci-dessus sont et seront amenées à évoluer. De plus d'autres restent encore déterminables en fonction de l'évolution du projet.

3.2 Matériels et méthodes

Prolongement du contexte scientifique.

Protocole expérimentale et du modèle biologique.

La génération des données bioinformatiques relatives aux analyses d'intérêt dépend en amont de la mise en place d'un protocole expérimental biologique soumis à l'utilisation d'un modèle animal particulier : le modèle AVI-PDX. Ce modèle a été conçu par l'entreprise Oncofactory[10], acteur du projet. Il consiste en la création très rapide de réplicats miniaturisés de tumeurs primaires pour chaque patient, réalisés par xénogreffe depuis l'extraction directe de cellules tumorales et avec comme hôte un embryon de poulet. Les molécules thérapeutiques sont délivrées à l'embryon pour une évaluation directe de leur efficacité. Cette technique permet de mimer l'hétérogénéité des tumeurs de patients, leurs réactivités face à la thérapie et leurs interactions avec le microenvironnement. Une fois les cellules greffées et soumises au traitement pendant 24 heures, une étape de dissociation enzymatique est effectuée afin d'extraire les cellules d'intérêts et d'analyser leur état. Ainsi, pour chaque patient nous obtenons à ce stade 3 différentes populations cellulaires tumorales séparées et confrontables : une première non soumise à la greffe (condition contrôle), une seconde soumise à la greffe mais non soumise au traitement (condition excipient) et une dernière soumise à la fois à la

greffe et au traitement (condition RCHOP). Ce protocole expérimental est appliqué en vue de nous permettre à termes de distinguer les effets propres à la greffe et propres au traitement. S'ensuit une étape de marquage par anticorps barcodés via un tag moléculaire propre à chaque condition, de sorte à labéliser chaque cellule comme appartenant à une condition particulière. Enfin, les 3 populations cellulaires sont regroupées en une.

Séquençage des libraries.

À partir du mélange des 3 conditions expérimentales, une librarie d'expressions géniques (ou librarie mRNA) est générée sur paillasse suivant le protocole Chromium 10X Next GEM Single Cell 3' v2 Chemistry / V(D)J Reagent Kits v1.1 de l'industrie 10X Genomics. Ce protocole offre une approche complète et évolutive en single cell pour obtenir des informations sur l'expression des gènes et le répertoire immunitaire d'une seule et même cellule. Le principe veut que chaque cellule soit associée à une perle 10X constituée d'UMIs et d'un barcode, le tout encapsulé dans une bulle d'huile et introduit dans une bille de gel en émulsion. S'ensuit une lyse cellulaire permettant aux transcrits exprimés d'être doublement labélisés : les séquences d'UMI de 10 nucléotides labélisent de manière unique tous les transcrits pour pallier le biais d'amplification, et un même barcode de 16 nucléotides labélise l'ensemble des transcrits comme ayant été exprimé par une même cellule. Les transcrits sont ensuite transformés en cDNA, amplifiés et fragmentés sur l'extrémité non labélisée, les faisant passer d'une taille initiale entre 400 et 10000 paires de bases à une taille réduite entre 300 et 600 paires de bases. Enfin des amorces R1 et R2 sont respectivement ajoutées aux extrémités de sorte à rendre le séquençage Illumina réalisable par l'entreprise Macrogène. Ce dernier est réalisé en paired-end jusqu'à hauteur de 150 paires de bases par molécules de cDNA. Ainsi 3 fichiers de sortis brutes au format BCL résultent du séquençage : un fichier R1 contenant l'information de label cellulaire dans lequel n'est gardé que les premières 26 paires de bases correpondant aux séquences nucléotidiques consécutives des barcodes et UMI relatives aux transcrits, un fichier R2 contenant l'information d'expression cellulaire issue des fragments de transcrits (ou reads) d'une longueur de 150 paires de bases, et un fichier d'index.

Le marquage par anticorps barcodés appliqué plus tôt permet l'élaboration d'une seconde librarie cellulaire, la librarie HTO. Celle-ci est réalisée en parallèle de la librarie mRNA, et permet la réalisation en aval d'une étape de démultiplexage. Lors de la lyse cellulaire, le tag moléculaire des anticorps barcodés marqué à la cellule est lui aussi soumis à une double labélisation, à l'image des transcrits grace au matériel de la perle 10X. À ce stade, chaque barcode cellulaire identifiant une cellule particulière se retrouve lié à un des 3 tags moléculaires relatant l'information d'appartenance de la cellule à une des 3 conditions expérimentales. Les tags des anticorps barcodés labélisés sont ensuite soustraits de la librairie mRNA entre l'étape d'amplification de fragmentation des transcrits sous forme cDNA, constituant une nouvelle librarie à part entière destiné à suivre le même protocole de séquençage.

Obtention des données d'expressions en single-cell.

Les pipelines de CellRanger nous donnent la possibilité d'analyser les données de séquençage produites à partir de protocole Chromium 10X. Ainsi les fichiers BCL issues du séquençage de la librarie mRNA et HTO sont convertis en fichier FASTQ via le logiciel CellRanger mkfastq. S'ensuit une étape d'alignement de transcrits grace au logiciel CellRanger Count, utilisant la librarie mRNA et la version GRCh38 du génome humain comme génome de référence. À l'issus de cette étape est généré un fichier matrice.mtx, matrice de comptage brute gènes/cellules et point de départ des analyses

d'expressions géniques. Est généré en même temps un fichier barcodes.tsv dans lequel se trouve la liste des barcodes et donc le nombre de cellules présentes à l'intérieur de la librairie mRNA à cette étape du protocole. À partir des fichiers FASTQ de la librarie HTO et du fichier barcodes.tsv, une étape de démultiplexage est réalisée dans le but de réassocier chaque barcode cellulaire à une des 3 conditions d'intérêt de départ. Cette étape est réalisé par le logiciel CITE-Seq-count, et nous fournis en sortie une matrice cellule/conditions, point de départ de la construction de métadonnées caractérisant nos cellules.

Expression géniques des différentes populations cellulaires.

La suite des analyses sont réalisées sur R, utilisant principalement dans un premier temps le package R Seurat[11]. Seurat est spécifiquement conçu pour l'analyse et l'exploration de données RNA-seq en single cell, et plus particulièrement dans le prolongement des expériences de 10X Genomics. Il vise à permettre aux utilisateurs d'identifier et d'interpréter les sources d'hétérogénéité des mesures transcriptomiques unicellulaires, et d'y superposer diverses informations catérgorielles en tant que métadonnées unicellulaires. D'abord, un objet Seurat est créer à partir du chargement de la matrice de comptage brute issus de la librairie mRNA construite par CellRanger. Seurat permet le croisement de tous types d'informations, nous permettant ainsi de faire le lien entre expression génique et condition pour chaque cellule à partir du chargement de la matrice cellule/conditions de la librairie HTO construite par CITE-SEQ-Count. De l'intersection des matrices résulte un seul et même objet Seurat, constitué à la fois d'une matrice de comptage d'expression mais aussi d'une matrice de métadonnées, avec autant de ligne que de cellules et pour l'instant une seule colonne pointant la condition expérimentale de chaque cellule.

Pré-traitement des données scRNA-seq.

Avant toute analyse, un prétraitement des données scRNA-seq est nécessaire[12]. Cette étape repose avant tout sur la sélection et l'application de filtres cellulaires sur la base de mesures de contrôle de qualité, la normalisation et mise à l'échelle des données, la détection des gènes hautement variables, ainsi que la clusterisation et l'ajout de réduction de dimension. L'intégralité des étapes est permise par Seurat, calculées, stockées et retrouvables dans l'objet Seurat initial et ce pour chaque patient. D'abord, un premier filtre est appliqué sur la base du nombre de gènes uniques détectés dans chaque cellule fixé entre 50 et 2500. Cela nous permet une filtration des billes vides, de mauvaise qualité ou des billes supportant l'inclusion de 2 cellules ou plus, présentant ainsi un nombre de gènes anormalement élevé. Parce qu'une cellule de mauvaise qualité ou mourante présente souvent une contamination mitochondriale importante, un second filtre est appliqué reposant sur le pourcentage de lectures qui correspondent à l'expression du génome mitochondrial. Nous ne gardons donc ici que les cellules dont ce pourcentage est inférieur à 5%.

Après avoir gardé uniquement les cellules d'intérêts, une normalisation du jeu de données est réalisée. La méthode de normalisation employée est celle dites "LogNormalize" qui normalise les mesures d'expressions des caractéristiques de chaque cellule par l'expression totale, multiplie cette dernière par un facteur d'échelle de 10 000 et transforme le résultat au logarithme.

Suite à cela est calculé un sous-ensemble de gènes qui présentent une forte variation d'une cellule à l'autre dans l'ensemble de données, ainsi appelés gènes hautement variables[13] et dont le nombre a ici été fixé à 2000[14]. Le fait de se concentrer sur ces gènes-là dans permet de mettre en évidence le signal biologique lors d'analyses de données en aval.

Enfin, une mise à l'échelle des données (ou "scalling") est nécessaire et constitue une étape de prétraitement standard enfin de rendre l'application des techniques de réduction dimensionnelle qui suivent réalisables et pertinantes. Ce scalling consiste à décaler l'expression de chaque gène, de sorte que l'expression moyenne entre les cellules soit égale à 0 et à mettre à l'échelle l'expression de chaque gène, de sorte que la variance entre les cellules soit égale à 1. In fine cette étape pondère l'expression de chaque gène dans les analyses en aval, de sorte que les gènes fortement exprimés n'écrase pas la tendance générale d'expression.

À l'issus de ces étapes de prétraitement, une premiere technique de réduction de dimension linéaire, l'analyse en composante principale, est réalisée sur la base des gènes hautement variables et dont le résultat permettra la clusterisation des cellules[15]. En effet, l'étape de clusterisation est effectuée via l'élaboration d'un graphe des K plus proches voisins (KNN) calculé à partir de la distance euclidienne entre cellules dans l'espace de l'ACP. La distance entre deux cellules aussi est podéré en fonction du chevauchement partagé dans leurs voisinages locaux (similarité de Jaccard). Le regroupement des cellules en cluster est ensuite réalisé via des techniques d'optimisation de modularité issues de l'algorithme de Louvain. Il en résulte premier un nombre de clusters qui rassemble les cellules les plus similaires entre elles, uniquement sur la base de l'expression des gènes les plus variables et sans autres informations à priori.

Enfin, sont ajouté 2 techniques de réduction de dimension non linéaire sur la base des précédents résultats calculés : les visualisations UMAP et tSNE, afin d'enrichir l'exploration de l'ensemble des données.

Identifications phénotypiques.

Sur la base des expressions géniques de notre matrice de comptage brute est appliqué une étape d'identifications phénotypiques des cellules. Pour cela est utilisé le package R Celldex[16] qui fournit un accès à plusieurs ensembles de données de référence sur les types cellulaires. Parmi les bases de données disponibles dans Celldex, 2 sont principalement utilisées ici. La première utilisée est la Database of Immune Cell Expression/eQTLs/Epigenomics, ou DICE[17], qui fournit les valeurs d'expression normalisées de 1561 échantillons RNA-seq en bulk provenant du projet du même nom à partir de populations pures de cellules immunitaires humaines. Cette référence est particulièrement utile si on vient à s'intéresser aux sous-ensembles de lymphocytes T CD4+. Elle expose en outre la possibilité de distinguer 15 sous populations parmi les grands types cellulaires suivant : lymphocyte B, lymphocyte T CD4+, lymphocyte T CD8+, monocytes, et cellule NK. La référence Blueprint/ENCODE est aussi utilisée, et est constituée de valeurs d'expression normalisées pour 259 échantillons RNA-seq en bulk à partir de populations pures de stroma et de cellules immunitaires générées par les projets Blueprint[18] et ENCODE[19] Cette référence convient aux échantillons mixtes et rassemble un plus large panel de sous population car elle permet en outre l'identification de 43 types cellulaires, agrégés en 24 grandes classes. Le package R SingleR[16] est utilisé ici pour annoter les types des cellules présentes dans l'ensemble du jeu de données directement à l'intérieur de nos objets Seurat dans notre tableau de métadonnées. En effet SingleR est une méthode d'annotation automatique pour les données de séquençage d'ARN en single cell (scRNAseq) et fonctionne de paire avec le package Seurat. De chaque base de données sont utilisée les 2 niveaux d'annotations du type de cellule offert par chacune d'elles. D'un côté est utilisé le label.main, annotation large qui définit les principaux types de cellules, comporte peu de niveaux uniques mais permet une annotation rapide à faible résolution. De l'autre est utilisé le label.fine, annotation plus spécifique qui définit les sous-types ou les états. Elle comporte plus de niveaux uniques, ce qui permet une annotation plus lente mais à une résolution beaucoup plus élevée. Chaque label de chaque base

de données identifie un type ou sous-type cellulaire pour chacune des cellules, ce qui constitura une colonne de métadonnées ajoutables au tableau de métadonnées de l'objet Seurat initial.

Enrichissement fonctionnel de gènes.

Toujours depuis la base des expressions géniques de notre matrice de comptage brute une étape d'enrichissement fonctionnel de gène est réalisée. Cette étape est permise via l'utilisation du package R Escape[20], créé pour relier les résultats du séquençage en single cell soit à partir de comptages bruts, soit à partir du package R Seurat avec les analyses d'enrichissement des ensembles de gènes utilisant les méthodes computation des Gene Set Enrichment Analysis (GSEA)[21][22]. Escape accède à la totalité de la base de données Molecular Signature Database v7.0 (Database MSigDB) permettant de sélectionner des ensembles de gènes uniques ou multiples pour effectuer l'analyse d'enrichissement. La première étape du processus d'analyse d'enrichissement des ensembles de gènes consiste en la sélection d'un ensemble de gènes utilisables depuis la base de données GSEA. L'espèce considérée étant Homo Sapiens, nous avons choisi de nous focaliser sur une collection appelée la Hallmark Gene Sets[23][24] provenant de la database MSigDB, réunissant 50 fonctions (ou Hallmark) qui condensent les informations de plus de 4 000 ensembles de gènes, représentent des états ou des processus biologiques spécifiques bien définis selon des tendances d'expressions. Une fois la base de données sélectionée, l'enrichissement sur les données de comptage est réalisé directement depuis l'objet Seurat construit à partir de la matrice de comptage brute. Pour chacune des cellules, un score d'enrichissement quantifiant la tendance d'expressions est calculé pour chacun des Hallmarks. À l'issus, pour chaque hallmark une colonne de score avec autant de ligne que de cellule est déterminé et ajoutées aux métadonnées de chaque objet Seurat d'intérêt.

Analyses des récepteurs BCR au sein des populations polyclonales des lymphocytes B.

Librarie VDJ CellRanger VDJ

Génotypage du transcriptome des cellules.

Librarie GoT IronThrone-GoT

Analyses de l'état de phase du cycle cellulaire.

Assigner l'état de phase du cycle cellulaire pour chacune des cellules du jeu de données est directement permis depuis les fonctions du package Seurat. Chaque état de phase est identifié à partir de l'élaboration d'une liste de gènes marqueur préalablement choisit[8]. Nous pouvons séparer cette liste en marqueurs de la phase G2/M et en marqueurs de la phase S. La première étape consiste en l'attribution pour chaque cellule de 3 scores, basés sur son expression des marqueurs de la phase G2/M et de la phase S. Les cellules n'exprimant ni l'un ni l'autre sont considérées comme étant probablement pas en cycle et donc ont un score de phase G1 plus élevé. Le plus haut score parmi les 3 scores obtenus véhicule la prédiction de la classification de chaque cellule en phase G2M, S ou G1[8]. Ainsi pour chaque cellule est assigné un état de phase du cycle cellulaire, et l'ensemble de ces informations s'ajoutent en une colonne dans nos tableaux de métadonnées de notre objet Seurat d'intérêt.

Superposition et manipulation des métadonnées : Application Shiny.

L'ajout d'un grand nombre de métadonnée visant à caractériser au maximum les cellules présentes dans chaque objet Seurat amène à réaliser un grand nombre d'analyses visuelles. Afin de pouvoir centraliser, faciliter et accélérer la génération et la visualisation des différents résultats, une application Shiny a été développée. Cette application s'élabore autour du chargement d'un objet Seurat incluant au préalable l'ensemble des analyses détaillées dans les parties précédentes. Parmi les différentes sections développées dans l'application, un premier panel expose un résumé des métadonnées les plus importantes présentes dans l'objet Seurat chargé. Ainsi sur sunrburst, on retrouve des pourcentages quantifiant : le taux de cellules dans les différentes conditions, le taux des différents types de populations et sous-populations cellulaires et le taux de cellule en phase G1, S et G2/M.

Un second panel offre la possibilité d'afficher la sortie brute des analyses de réductions de dimension linéaire (ACP) et non linéaire (UMAP et tSNE) et 2 dimensions et 3 dimensions. L'application a été développée de manière pouvoir visualiser la part de variabilité expliquée par chacune des métadonnées sur ces sorties brutes, donnant lieux à une potentielle première interprétation des facteurs en composante principales. De plus, des options "group by" et "split by" ont ausi été mis en place de façon à pouvoir approfondir les interprétations en superposant simultanément différentes informations retrouvées dans les métadonnées, élement utile dans le croisement des données et l'élaboration de corrélation ou anticorrélation entre métadonnées. Enfin l'application intégre aussi à ce niveau la possibilité de superposer à ces dernières figures l'expression de chacun des gènes retrouvés exprimés dans le jeu de données, afin de directement croiser l'information de la matrice de comptages brutes avec les caractéristiques descriptives du tableau de métadonnées.

Un troisième panel a été développé de façon à centraliser les résultats issus de la matrice d'expression et de l'enrichissement fonctionnelle de gènes. Une première heatmap de corrélation est élaborée via le top 10 des gènes les plus différentiellement exprimés véhiculant chaque condition expérimentale. Les informations statistiques corrélées type p valeur et log2fold change sont aussi montrées. Ensuite, un second sous panel se focalise sur l'enrichissement de gène, où là une heatmap de corrélation basée sur l'ensemble des scores des 50 hallmarks est réalisée. Cette heatmap donne en plus la possibilité de se focaliser simultanément sur tous ou certains hallmarks mais aussi de clusteriser la heatmap selon un type de métadonnée choisi, laissant l'opportinité de croiser à nouveau les tendances d'expressions géniques avec les caractéristiques des cellules.

Enfin un dernier panel expose des figures permettant de comparer visuellement le taux de cellule obtenue avant et après application de filtres basés sur des mesures de contrôle de qualité.

Identification des ressources et intéraction avec un cluster de calcul à haute perfomance.

3.3 Résultats

Une section présentant les résultats obtenus ;

1.

2.

3.4 Discussion

Une section discussion qui contextualise les résultats par rapport à la problématique et au contexte général dans lequel s'inscrit le stage ;

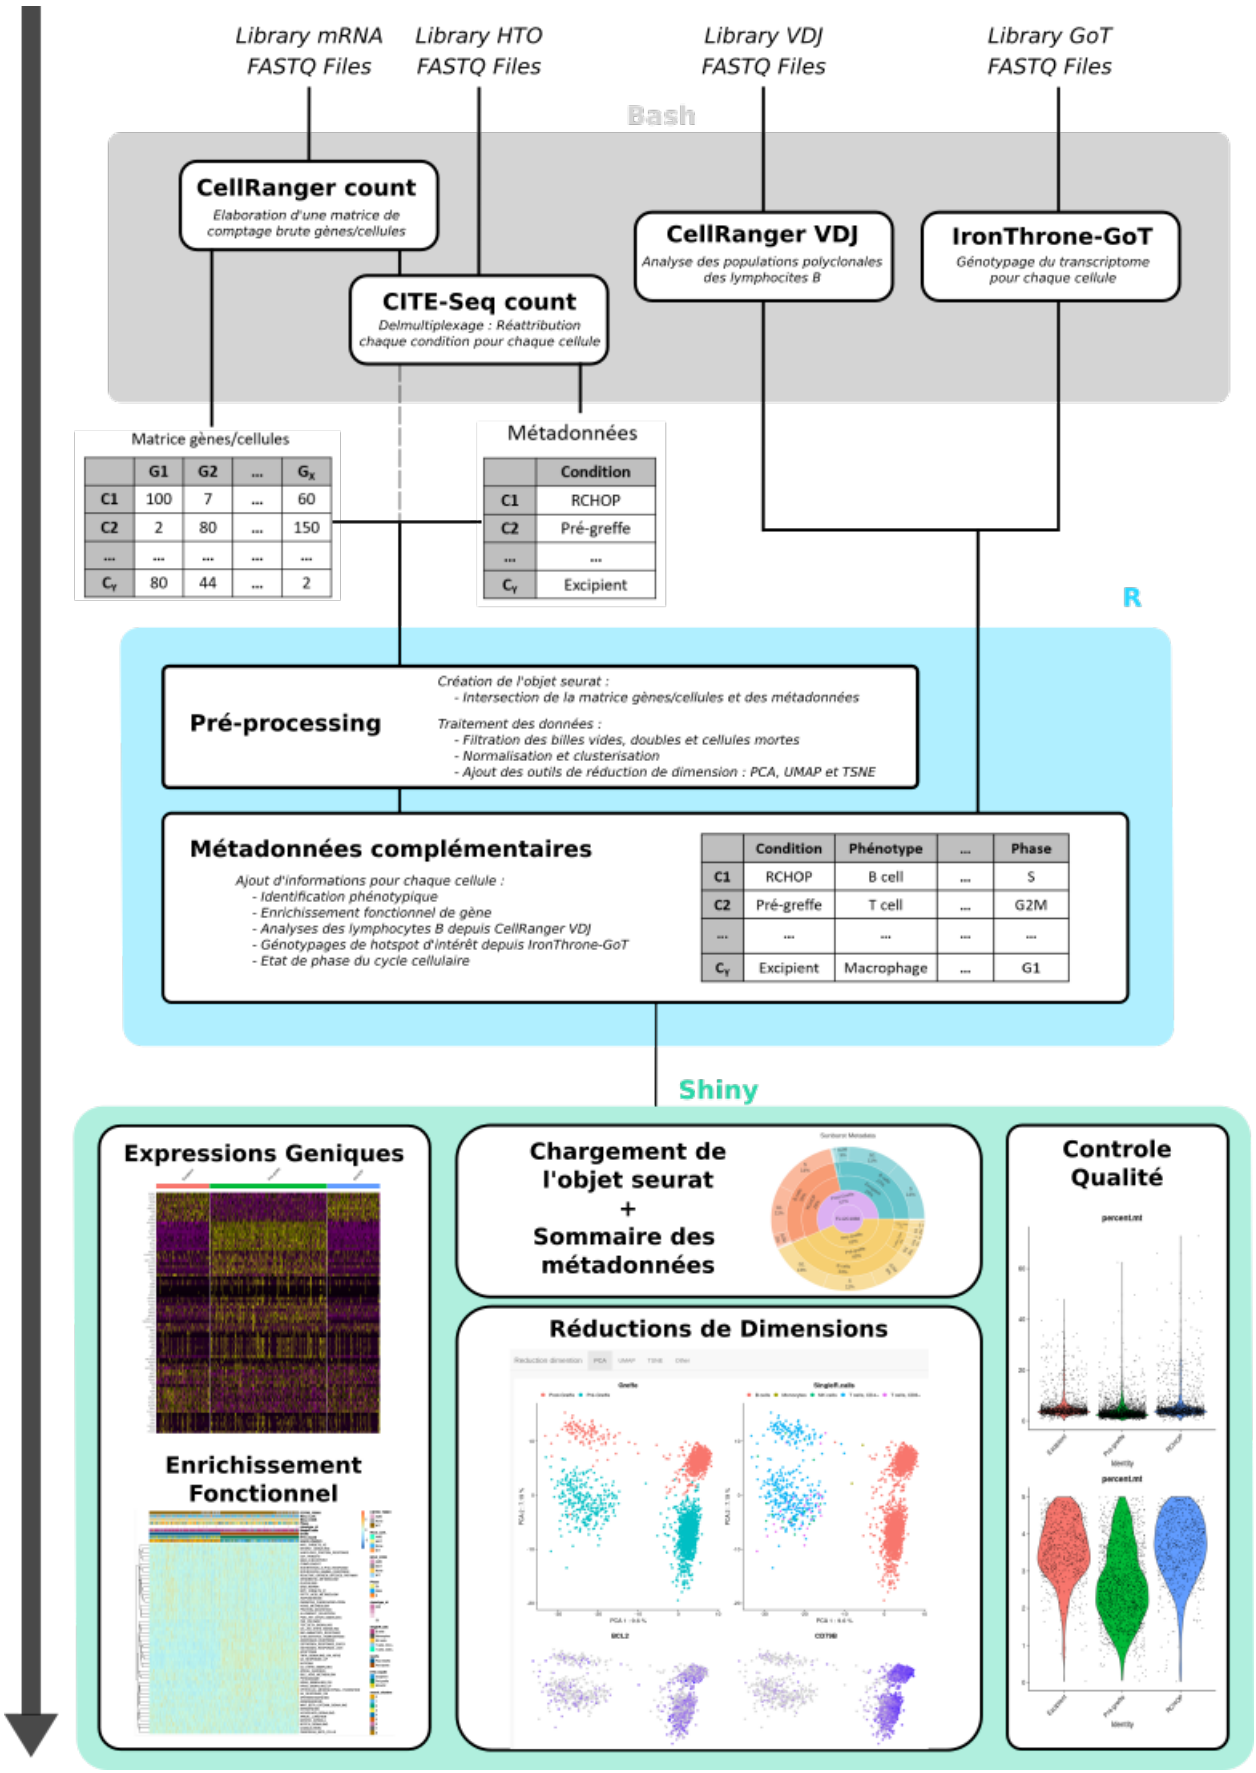

Figure 1: Workflow des analyses du projet FLINOVO

3.5 Conclusion

Une conclusion qui présente également les perspectives ouvertes par le travail réalisé.

4. Bibliographie

[1] McGranahan N. et Swanton C. Biological and therapeutic impact of intratumor heterogeneity in cancer evolution. *Cancer Cell*, 27(1):15–26, 2015.

[2] Huet S. et al. A gene-expression profiling score for prediction of outcome in patients with follicular lymphoma: a retrospective training and validation analysis in three international cohorts. *Lancet Oncology*, 19(4):549 – 561, April 2018. Erratum in: Correction to Lancet Oncol 2018; 19: 549-61. [Lancet Oncol. 2018].

[3] Greaves M. et Maley C. C. Clonal evolution in cancer. *Nature*, 481:306–313, 2018.

[4] Salles G. et al. Rituximab maintenance for 2 years in patients with high tumour burden follicular lymphoma responding to rituximab plus chemotherapy (prima): A phase 3, randomised controlled trial. *Lancet*, 377:42–51, 01 2011.

[5] Hiddemann W. et Cheson B. How we manage follicular lymphoma. *Leukemia*, 28, 02 2014.

[6] Richard A. et al. Single-cell-based analysis highlights a surge in cell-to-cell molecular variability preceding irreversible commitment in a differentiation process. *PLOS Biology*, 14(12):1–35, 2016. e1002585.

[7] Hwang B. Lee J. H. et Bang D. Single-cell rna sequencing technologies and bioinformatics pipelines. *Experimental and Molecular Medicine*, 50(96), 2018.

[8] Tirosh I. et al. Dissecting the multicellular ecosystem of metastatic melanoma by single-cell rna-seq. *Science*, 352(6282):189–196, 2016.

[9] Li H. et al. Reference component analysis of single-cell transcriptomes elucidates cellular heterogeneity in human colorectal tumors. *Nature Genetics*, 49:708–718, 2017.

[10] Delloye-Bourgeois C. et al. Microenvironment-Driven Shift of Cohesion/Detachment Balance within Tumors Induces a Switch toward Metastasis in Neuroblastoma. *Cancer Cell*, 32(4):427–443.e8, October 2017.

[11] Hao Y. et al. Integrated analysis of multimodal single-cell data. *bioRxiv*, 2020.

[12] Ilicic T. et al. Classification of low quality cells from single-cell rna-seq data. *Genome Biology*, 17, 02 2016.

[13] Brennecke P. et al. Corrigendum: Accounting for technical noise in single-cell rna-seq experiments. *Nature methods*, 10, 09 2013.

[14] Stuart T. et al. Comprehensive integration of single cell data. 11 2018.

[15] Macosko E. et al. Highly parallel genome-wide expression profiling of individual cells using nanoliter droplets. *Cell*, 161:1202–1214, 05 2015.

[16] Dvir A. et al. Reference-based analysis of lung single-cell sequencing reveals a transitional profibrotic macrophage. *Nat. Immunol.*, 20:163–172, 2019.

[17] Schmiedel B. et al. Impact of genetic polymorphisms on human immune cell gene expression. *The Journal of Immunology*, 202(1 Supplement):182.27–182.27, 2019.

[18] Joost H.A. Martens and Hendrik G. Stunnenberg. Blueprint: mapping human blood cell epigenomes. *Haematologica*, 98(10):1487–1489, Oct. 2013.

[19] Bernstein et al. An integrated encyclopedia of dna elements in the human genome. *NATURE*, 489(7414):57–74, September 2012.

[20] Vishwakarma A. et al. Mapping the immune landscape of clear cell renal cell carcinoma by single-cell rna-seq. *bioRxiv*, 2019.

[21] Subramanian A. et al. Gene set enrichment analysis: A knowledge-based approach for interpreting genome-wide expression profiles. *Proceedings of the National Academy of Sciences*, 102(43):15545–15550, 2005.

[22] Mootha V. et al. Pgc-1 alpha-responsive genes involved in oxidative phosphorylation are coordinately downregulated in human diabetes. *Nature genetics*, 34:267–73, 08 2003.

[23] Liberzon A. et al. Molecular signatures database (MSigDB) 3.0. *Bioinformatics*, 27(12):1739–1740, 2011.

[24] Liberzon A. et al. The molecular signatures database hallmark gene set collection. *Cell Systems*, 1(6):417 – 425, 2015.